

# Rachunek Prawdopodobieństwa

## ZADANIE DOMOWE 2

Termin wysyłania (MS Teams): **26 listopada 2025 godz. 23:59**

**Zadanie 1.** *Kule i urny*, patrz np. rozdział 5 w [MU17]

Jednym z klasycznych modeli probabilistycznych mającym zastosowania w algorytmice jest model kul i urn (ang. *balls and bins*). W modelu tym  $m$  kul kolejno wrzucanych jest niezależnie i jednostajnie losowo do  $n$  ponumerowanych urn. Wrzucenie  $m$  kul do  $n$  urn w taki sposób możemy utożsamiać z losową funkcją ze zbioru  $\{1, \dots, m\}$  w zbiór  $\{1, \dots, n\}$  (formalnie, przestrzenią zdarzeń elementarnych jest wówczas zbiór  $\Omega_{n,m} = \{1, \dots, n\}^{\{1, \dots, m\}}$ ).

Celem tego zadania jest eksperymentalne wyznaczenie następujących wielkości:

- (a)  $B_n$  – moment pierwszej kolizji;  $B_n = k$ , jeśli  $k$ -ta z wrzucanych kul jest pierwszą, która trafiła do niepełnej urny (**paradoks urodzinowy**, ang. *birthday paradox*),
- (b)  $U_n$  – liczba pustych urn po wrzuceniu  $n$  kul,
- (c)  $C_n$  – minimalna liczba rzutów, po której w każdej z urn jest co najmniej jedna kula (pierwszy moment, w którym nie ma już pustych urn; **problem kolekcjonera kuponów**, ang. *coupon collector's problem*),
- (d)  $D_n$  – minimalna liczba rzutów, po której w każdej z urn są co najmniej dwie kule (*the siblings of the coupon collector / coupon collector's brother*),
- (e)  $D_n - C_n$  – liczba rzutów od momentu  $C_n$  potrzebna do tego, żeby w każdej urnie były co najmniej dwie kule.

Zaimplementuj symulacje obejmujące wykonanie dla każdego  $n \in \{1000, 2000, \dots, 100\,000\}$  po  $k = 50$  niezależnych powtórzeń eksperymentu wrzucania kul do urn i zapisanie (np. do pliku) wszystkich powyższych statystyk. Pojedyncze powtórzenie eksperymentu może polegać na wrzucaniu kul aż do pierwszego momentu, w którym w każdej z urn są co najmniej dwie kule i zliczaniu „po drodze” badanych statystyk.

Zadbaj o to, aby generator liczb pseudolosowych użyty w symulacjach był „dobry” (tj. miał dobre własności statystyczne). Przykładowo, standardowa implementacja funkcji `rand()` w języku C nie jest dobrym generatorem. Możesz wykorzystać np. generator Mersenne Twister.

Po zakończeniu symulacji, korzystając z zebranych danych, dla każdej z badanych zmiennych losowych ( $B_n$ ,  $U_n$ ,  $C_n$ ,  $D_n$  oraz  $D_n - C_n$ ) przedstaw na wykresach za pomocą wybranego narzędzia (np. *numpy*, *Matlab*, *Mathematica*, ...) wyniki poszczególnych powtórzeń ( $k$  punktów danych dla każdego  $n$ ) oraz ich wartość średnią jako funkcję  $n$ . Wyniki poszczególnych prób oraz ich średnie nanieś na wspólny wykres tak, aby można było łatwo określić ich koncentrację wokół wartości średniej.

Dodatkowo wykonaj następujące wykresy (poniżej  $b(n)$ ,  $u(n)$ ,  $c(n)$  i  $d(n)$  oznaczają, odpowiednio, średnią wartość  $B_n$ ,  $U_n$ ,  $C_n$  i  $D_n$  dla danego  $n$ ):

- (a) iloraz  $\frac{b(n)}{n}$  oraz  $\frac{b(n)}{\sqrt{n}}$  jako funkcja  $n$ ,

- (b) iloraz  $\frac{u(n)}{n}$  jako funkcja  $n$ ,
- (c) iloraz  $\frac{c(n)}{n}$ ,  $\frac{c(n)}{n \ln n}$  oraz  $\frac{c(n)}{n^2}$  jako funkcja  $n$ ,
- (d) iloraz  $\frac{d(n)}{n}$ ,  $\frac{d(n)}{n \ln n}$  oraz  $\frac{d(n)}{n^2}$  jako funkcja  $n$ ,
- (e) iloraz  $\frac{d(n) - c(n)}{n}$ ,  $\frac{d(n) - c(n)}{n \ln n}$  oraz  $\frac{d(n) - c(n)}{n \ln \ln n}$  jako funkcja  $n$ .

**Uwaga.** W ZADANIU DOMOWYM 3. będziemy dalej pracować z modelem kul i urn w kontekście zastosowań algorytmicznych (problem *balanced allocation*). Warto więc przygotować implementację tak, żeby można było ją ponownie wykorzystać (po odpowiednich modyfikacjach). Tam będziemy badać m.in. maksymalną liczbę kul w urnie po wrzuceniu  $n$  kul (*maximum load*).

**Zadanie 2.** Przedstaw wyniki eksperymentów z zadania 1. i odpowiedz na poniższe pytania.

- Zaprezentuj wykresy, zwięźle omów uzyskane rezultaty i przedstaw wnioski.
- Na podstawie wykresów krótko scharakteryzuj koncentrację wyników uzyskanych w poszczególnych powtórzeniach wokół wartości średniej dla badanych wielkości.
- Na podstawie wykresów postaw hipotezy odnośnie asymptotyki wartości średnich badanych wielkości i uzasadnij ich wybór (w razie potrzeby w niektórych wykresach możesz zastosować skalę logarytmiczną).
- Zaproponuj rozsądne uzasadnienie użycia nazw *birthday paradox* oraz *coupon collector's problem* pojawiających się w zadaniu 1. (przedstaw stojące za nimi intuicje).
- Jakie znaczenie ma *birthday paradox* w kontekście funkcji hashujących i kryptograficznych funkcji hashujących?

---

Rozwiązanie zadania obejmujące

- implementację symulacji (kod źródłowy w wybranym języku programowania) oraz
- uzyskane wyniki i wyciągnięte na ich podstawie wnioski (pdf z wykresami i samodzielnie napisanymi **zwięzłymi** opisami wyników, wnioskami oraz odpowiedziami do zadania 2)

należy przesłać na platformę MS Teams. Nie należy dołączać żadnych zbędnych plików.

## Literatura

[MU17] Michael Mitzenmacher and Eli Upfal. *Probability and Computing. Randomization and Probabilistic Techniques in Algorithms and Data Analysis*. Cambridge University Press, 2nd edition, 2017.